音频智能三项目 详细实现方案

听析 · 清听 / 音审通 · 声刻

可行性判断	架构与模块拆解	实施顺序与里程碑
从立项表起步，三项均可实现，难易指标、费用代表性数据复现	以共享音频 AI 底座承载预处理、模型、评测、任务与报告	共享底座 → 2 → 1 → 3，8 周内，小团队约 10 周

版本 1.0 | 2026-09-20 | 依据项目简介与公开一手技术资料编制

01 结论先行

回答三个问题：能不能做、先做什么、成功如何判定。

总体结论：可以实现，但当前不是“接手已有工程”，而是从零搭建。现有输入仅包含项目简介；目录中没有代码、数据、权重、实验记录或基础设施。因此，简介中的 98.56% Accuracy、98.42% Macro F1、MOS 提升和“PESQ / DNSMOS 显著提升”只能作为目标或待核验陈述，不能直接作为已完成成果。

项目	可实现性	MVP 难度	最大不确定性	建议定位
2 清听· 音审通	高	中	真实噪声/回声分布；合规规则边界	第一个落地，建立共享音频底座
1 听析	高	中-高	分类数据域迁移；长音频 Agent 可靠性	第二个落地，形成业务可见的分析产品
3 声刻	中-高	高	音色授权；情感可控性；盲听统计	最后落地，作为生成侧高风险能力

推荐顺序



为什么不从“听析”直接开始：它依赖稳定的音频标准化、VAD、ASR、质量评分和可追溯任务记录；这些恰好是项目 2 的基础产物。为什么“声刻”最后：它既依赖干净样本和统一评测，又多出授权、冒用、声纹相似度与主观听测风险。

基准工期

交付口径	人员假设	日历工期	说明
作品集型 MVP	1 名全职，1 张 24GB NVIDIA GPU	26-34 周	顺序推进，优先可演示与可复现
可试点版本	3-4 人小队，1-2 张 24-48GB GPU	约 18 周	底座完成后并行；含数据、后端、算法与测试
生产化	再增加安全、SRE、法务/运营	+8-16 周	取决于 SLA、并发、内容治理与部署环境

02 当前基础、假设与边界

先把事实、假设与需要验证的指标分开，避免方案建立在隐含前提上。

2.1 当前盘点

维度	当前状态	对实施的影响
代码仓库	空目录	需新建 monorepo、分支保护、CI、镜像与版本规范
数据	未提供	所有准确率、WER、PESQ、DNSMOS、MOS 均无法复核
模型	未下载且版本未锁定	需记录模型 ID、revision、权重校验和与许可
硬件	未说明	训练与高吞吐推理应假设 Linux + NVIDIA CUDA；macOS 仅做编排/轻量开发
业务规则	未提供	敏感内容、情绪标签、分类标签、报告字段要由产品/法务确认
安全授权	未提供	语音克隆必须建立说话人知情同意与撤销机制

2.2 默认实施假设

- 优先支持中文普通话，兼顾中英混合；方言、多语种和歌曲识别列为扩展验收集。
- 离线批处理优先，实时流式作为第二阶段；所有服务都提供同步查询与异步作业接口。
- 原始音频不可变保存，派生文件按处理链版本化；个人敏感信息按最小权限与保留期管理。
- 模型先采用开源预训练权重完成基线，再根据真实误差决定是否微调；不为“用了深度学习”而微调。
- 部署基线为 Linux 容器 + NVIDIA GPU；CPU 路径用于 RNNoise、队列消费者、单元测试与轻量回退。

2.3 指标承诺规则

每个指标必须同时绑定：数据集版本、划分、采样率、模型 revision、推理参数、硬件、随机种子和置信区间。内部测试集如果包含同一说话人、同一录音或同一音源的切片，必须按“源文件/说话人”分组切分，禁止泄漏。

简介中的陈述	方案中的处理方式
分类 Accuracy 98.56%、Macro F1 98.42%	设为待复现 Gate；增加跨域集、少数类召回与校准误差
PESQ / DNSMOS 显著提升	报告绝对值、均值差、置信区间和负向样本比例；PESQ 需精确说明实现与许可
3-10 秒少样本克隆	视为 zero-shot / few-shot 推理目标；真正微调另需更长、干净且授权的数据
MOS 提升	采用随机、双盲、耳机筛查、足够听众与显著性检验

03 共享架构：一套底座，三个产品

避免三个仓库各自重复处理音频、模型、任务、评测和报告。



3.1 逻辑组件

组件	职责	建议实现	被谁复用
Audio I/O	格式探测、解码、单/双声道策略、采样率转换、分片	FFmpeg + soundfile；hash 去重	1 / 2 / 3
Feature Store	VAD 区间、LUFS、峰值、频谱、嵌入、转写	PostgreSQL 元数据 + 对象存储文件	1 / 2 / 3
Model Gateway	统一批处理/流式接口，记录模型 revision 与运行参数	FastAPI + 独立 GPU worker	1 / 2 / 3
Job Orchestrator	异步作业、重试、幂等、超时、取消、进度	Celery/RQ/Temporal 三选一；MVP 可先 Celery	1 / 2
Agent Runtime	条件分支、循环、工具调用、状态与人工确认	LangGraph；MCP 作为工具互操作边界	1，后续可编排 2 / 3
Evaluation Hub	离线基准、回归门禁、盲听任务、结果追踪	pytest + DVC/MLflow 可选 + 静态报告	1 / 2 / 3
Audit & Safety	请求主体、输入授权、策略命中、输出水印/追踪	不可变审计事件 + RBAC	1 / 2 / 3

3.2 建议仓库结构

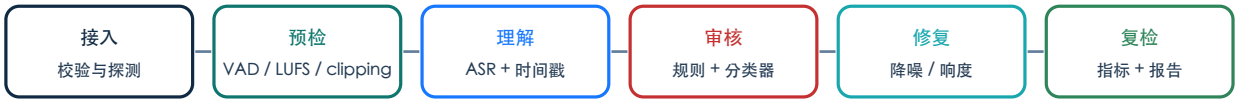
路径	内容
apps/tingxi-api	听析 API 与 LangGraph 图
apps/qingting-qc	修复/质检任务与报告服务
apps/shengke-tts	克隆、情感合成与安全策略
packages/audio-core	I/O、VAD、重采样、LUFS、切片、数据契约
packages/model-adapters	Whisper、FunASR/Qwen3-ASR、DeepFilterNet、RNNoise、CosyVoice、GPT-SoVITS 适配器
packages/evaluation	WER/CER、分类、PESQ/POLQA、DNSMOS、SI-SDR、MOS 统计
infra/	Docker、Compose、K8s 可选、GitHub Actions、部署清单
datasets/manifests	只存清单、许可、hash、划分与 lineage，不提交原始敏感音频

关键约束：MCP 不替代服务内稳定接口。高吞吐模型调用走内部 gRPC/HTTP；MCP 面向 Agent 的“可发现工具”层，并为每个工具设置 schema、超时、幂等键、最大音频时长和权限。

04 项目 2：清听· 音审通 - 先做的原因与范围

它不是单一降噪模型，而是共享音频数据与质量工程的起点。

4.1 MVP 范围



优先级	包含	暂不包含
P0	WAV/MP3/M4A；离线批量；VAD；LUFS；削波检测；DeepFilterNet / RNNoise 基线；ASR；结构化 JSON/PDF 报告	实时麦克风、复杂多通道波束形成
P1	去混响基线、回声场景检测、敏感词与 PII、人工复核队列、Docker GPU/CPU 镜像	端到端神经 AEC 的生产承诺
P2	场景自适应模型路由、流式处理、域内微调、K8s 弹性	未经数据验证的全自动发布

4.2 修复链的正确顺序

步骤	操作	为什么
1	解码、声道与采样率标准化	统一后续算法输入；保存原始文件
2	VAD / 静音标注而非立即删除	会议停顿可能有语义；保留时间轴
3	削波、DC、峰值与噪声画像	先识别故障类型，再路由模型
4	AEC / 去混响（若适用）	回声与混响会干扰降噪；但错误处理可能伤害直达声
5	降噪	DeepFilterNet3 适合 48kHz 全频带语音；RNNoise 作为低延迟 CPU 基线
6	响度标准化与真峰值限制	放在增强后，避免先放大噪声；目标按平台场景配置
7	ASR/质检与双轨输出	对原始轨和修复轨同时评测，防止“更干净但更难识别”

4.3 首个可演示闭环

上传 10 段问题音频 → 自动识别格式与故障 → 生成原始/修复 A-B 对比 → 输出 LUFS、clipping、DNSMOS、WER/CER 变化 → 标出敏感片段时间码 → 导出 JSON + PDF 报告。该闭环比单独展示波形更能证明工程价值。

05 项目 2：模型、数据与评测设计

目标是“改善且不伤害”，因此必须设置多指标门禁与负向案例库。

5.1 基线矩阵

能力	Baseline A	Baseline B	升级路径	选择标准
降噪	RNNoise CPU	DeepFilterNet3	域内增广/微调	DNSMOS、SI-SDR、RTF、ASR 退化率
VAD	WebRTC VAD	Silero/FSMN VAD	域内阈值校准	漏语音率、虚警率、边界误差
ASR	Whisper turbo	Qwen3-ASR 0.6B / FunASR	按场景路由或热词	CER/WER、时间戳、RTF、显存
响度	EBU R128 / loudnorm	pyloudnorm	分场景策略	集成 LUFS、LRA、True Peak
内容审核	词典/正则	文本分类器	人工复核 + 策略版本	召回优先、误报成本、可解释证据

5.2 数据集分层

层	组成	用途	防泄漏规则
公开基线	DNS Challenge、VoiceBank+DEMAND、公开 RIR/噪声	快速复现、与论文对照	按官方划分；记录许可与版本
合成域	干净语音 × 噪声 × RIR × SNR × codec	覆盖长尾和受控消融	clean/noise/RIR 三方均按源分组
真实域	客服、会议、播客、影视授权样本	最终上线门禁	按客户/节目/设备/说话人分组
失败库	音乐、耳语、重叠说话、强混响、削波、非语音	防回归与模型路由	每次事故新增最小复现样本

5.3 评测门禁

维度	指标	MVP 通过条件（建议，需基线实测后冻结）
音质	DNSMOS SIG/BAK/OVRL	总体均值改善；每个主要场景报告 95% CI；负向比例受控
有参考增强	SI-SDR / STOI；PESQ 仅作历史对照	相对 baseline 提升；列出被伤害样本
识别可用性	CER/WER 原始 vs 修复	修复后不得系统性变差；关键域设非劣门槛
响度	Integrated LUFS / True Peak / LRA	命中场景配置；无新增削波
效率	RTF、P50/P95、峰值显存	离线批量满足容量模型；模型超时可降级
审核	Recall / Precision / F2 + 人审通过率	高风险类别优先召回；所有命中可定位到时间码

注意：ITU-T P.862/PESQ 已被撤销并由 P.863 系列接替；PESQ 仍可用于历史对比，但需要说明版本、实现、窄带/宽带设置及使用许可。生产质量分不应只依赖一个模型分数。

06 项目 2：8 周 MVP 工作包

每周都有可验证产物；第 4 周即可展示最小闭环。

周	工作包	主要产物	退出条件
W1	仓库与数据契约	音频 manifest、作业状态机、Docker/CI 骨架	样例作业可幂等重跑
W2	Audio Core	FFmpeg 探测、VAD、重采样、LUFS、clipping	Golden files 通过；时间轴不漂移
W3	增强基线	RNNoise / DeepFilterNet3 适配器与 A-B 产物	批量 100 文件无崩溃；参数可追溯
W4	ASR 与报告	Whisper + Qwen3-ASR/FunASR 一组；JSON/PDF 报告	报告可回链到片段与处理链
W5	评测集	合成集、真实小集、失败库；指标 runner	一条命令产生可重复基准
W6	内容审核	词典/正则、文本分类、PII 脱敏、人审接口	命中均带证据与策略版本
W7	鲁棒性	重试、取消、超时、CPU 回退、异常格式	故障注入与资源上限通过
W8	验收与演示	性能报告、模型卡、运行手册、演示集	P0 Gate 全绿；已知限制签字

建议 API

接口	说明	关键字段
POST /v1/audio/jobs	创建质检/修复作业	input_uri, operations, policy_id, idempotency_key
GET /v1/audio/jobs/{id}	查进度与失败原因	status, stage, progress, error_code
GET /v1/audio/jobs/{id}/report	结构化报告	input_metrics, output_metrics, findings, lineage
GET /v1/audio/jobs/{id}/artifacts	签名下载链接	original, enhanced, clips, transcript

关键测试

- 单元：采样率、声道、VAD 边界、LUFS、true peak、时间码换算、策略规则。
- 契约：每个模型适配器的输入/输出 schema；模型缺失、OOM、超时与空音频。
- 回归：固定 20-50 个 Golden Audio，比较指标、波形长度、报告字段与 artifact hash。
- 性能：10/100/1000 文件批量，记录吞吐、P95、显存、CPU、磁盘和队列积压。
- 安全：恶意媒体、超长文件、路径穿越、模型供应链、敏感日志与下载链接过期。

07 项目 1：听析 - 产品闭环与 Agent 边界

Agent 负责决策与编排，确定性 DSP/模型能力仍由可测试工具执行。

7.1 用户闭环



示例：“把这批客服录音先降噪，找出退款原因和高风险情绪，按产品线归档，并生成带时间码的周报。”图执行时先验证权限与文件，再调用项目 2 的预处理/ASR
工具，接着抽取结构化事实、检索产品政策，最后生成引用片段的报告。

7.2 LangGraph 状态设计

状态字段	用途	约束
request / tenant / policy	用户意图、租户、权限与策略版本	进入任何工具前冻结；变更需新作业
assets[]	原始文件、派生文件、hash、时长、授权	原始文件不可覆盖
segments[]	VAD、说话人、时间码、转写、情绪、分类	全部结论可回链到时间段
tool_runs[]	工具名、版本、输入摘要、输出、耗时、错误	幂等；包含 model revision
evidence[]	知识库文档 ID、chunk、版本、匹配分	报告事实必须有音频或知识证据
draft / review / final	草稿、自动校验、人工确认、最终报告	高风险动作需人工确认

7.3 图节点与路由

节点	进入条件	输出 / 下一步
validate_input	所有请求	合法 → plan；不合法 → reject
plan	输入合法	生成受 schema 约束的任务图，不直接执行任意代码
quality_gate	音频可读	质量足够 → ASR；否则 → enhance → quality_gate，最多 1 次循环
transcribe	语音段存在	带时间戳文本；失败时模型回退或人工
classify/analyze	转写或声学特征可用	类别、情绪、实体、置信度与证据
retrieve	需要业务知识	租户隔离检索；过滤过期文档
compose/verify	证据齐备	结构化报告；无证据结论降级为“不确定”

08 项目 1：音频分类与 ASR 评测

先做强基线和严格划分，再决定 CRNN 是否真的优于传统模型。

8.1 分类实验矩阵

层次	输入	模型	目的
传统基线	MFCC、chroma、spectral centroid/bandwidth/contrast、ZCR	SVM / Random Forest / Logistic Regression	快速发现数据泄漏与易分特征
浅层神经	log-Mel	MLP / 小型 CNN	建立可部署基线
时序模型	log-Mel 序列	CNN + 双向 GRU（CRNN）	学习音色与时间结构
迁移表征	预训练音频嵌入	线性层 / 小型 MLP	比较小数据和跨域泛化

数据切分必须以原始曲目/录音会话为 group。若先切成片段再随机划分，几乎相同的声学片段会同时进入训练集与测试集，98% 指标可能虚高。

评测集	用途	必须报告
ID 测试集	同来源、不同曲目/说话人	Accuracy、Macro/Weighted F1、每类 P/R/F1、混淆矩阵
OOD-设备	不同麦克风、编码、采样率	相对下降、校准误差、拒识率
OOD-内容	不同曲风/演奏技法/背景声	Macro F1、少数类 Recall、top-k
开放集	训练标签之外的声音	AUROC/AUPR、unknown 检出率

8.2 ASR 选型协议

候选	强项假设	重点验证	不可直接假设
Whisper turbo	生态成熟、多语种、MIT	中文 CER、长音频、时间戳、噪声鲁棒性	所有中文业务域都最优
FunASR / Fun-ASR-Nano	中文工具链、VAD/标点/热词生态	具体模型卡、权重许可、方言与热词	FunASR 代码许可等于所有权重许可
Qwen3-ASR 0.6B / 1.7B	52 种语言/方言，离线与流式统一	显存、并发、长音频、时间戳/强制对齐	官方基准可替代本地业务评测

统一测试：安静/噪声、近讲/远讲、普通话/方言/中英混合、重叠说话、数字/专名、长音频。记录 CER/WER、hallucination rate、漏段率、时间戳偏差、RTF、P50/P95、显存和单位音频成本。

09 项目 1：RAG、可靠性与 10 周 MVP

RAG 的价值不是“多一个向量库”，而是让报告中的业务判断可引用、可更新、可撤回。

9.1 知识库设计

环节	做法	验收
摄取	政策、FAQ、产品资料、历史优质报告；记录 tenant、版本、有效期、权限	过期/越权文档不可被检索
切分	按标题/条款/表格语义切分；保留文档层级与页码	引用可回到原文位置
索引	稠密向量 + BM25 混合检索；可选 reranker	离线 query set 的 Recall@k / nDCG
生成	音频事实与知识条款分栏；只基于 evidence 输出结论	引用完整率、faithfulness、拒答率
更新	版本化重建、灰度验证、可回滚	同一报告可复现当时知识快照

9.2 防幻觉与失败策略

- 工具输出使用 JSON Schema 校验；禁止 Agent 直接拼接 shell 或任意文件路径。
- 所有结论分为 observed（音频直接证据）、retrieved（知识证据）、inferred（模型推断）三类。
- 置信度低、证据冲突、内容高风险时转人工；报告明确显示“不确定”，不补写缺失事实。
- LangGraph 循环设置次数和预算上限；工具失败采用显式降级，不无限重试。
- Prompt injection 防护：转写文本与知识文档都视为不可信数据，不能覆盖系统策略。

9.3 10 周工作包

周	重点	可验收产物
W1-2	复用 Audio Core；ASR benchmark	两到三套 ASR 在代表集上的质量/效率报告
W3-4	分类数据与基线	SVM/RF/MLP/CNN/CRNN 对比；严格 group split；混淆矩阵
W5	工具服务与 MCP	transcribe/classify/enhance/evaluate 四个有 schema 的工具
W6-7	LangGraph 状态图	条件分支、单次质量循环、错误恢复、审计轨迹
W8	RAG	租户隔离、混合检索、引用、离线检索评测
W9	报告与人审	内容总结、关键信息、情绪/分类、证据时间码
W10	红队与演示	注入、超时、幻觉、越权、长音频；一键演示

10 项目 3：声刻 - 可实现，但需重新定义“3-10 秒微调”

3-10 秒样本更适合 zero-shot / few-shot 克隆；稳定微调通常需要更多干净、标注且授权的数据。

10.1 范围分层

层	能力	现实预期	验收方式
P0 Zero-shot	3-10 秒参考音频 + 文本 → 克隆音色	可做；效果受参考音质、口音与文本覆盖影响	说话人相似度 + ASR CER + 盲听 MOS
P1 指令情感	高兴/悲伤/严肃/温柔、语速、音量、方言	CosyVoice 3 类模型可作为主路径；精细强度需校准	情感识别准确率 + 强度排序 + MOS
P1 Few-shot	约 1 分钟及以上清洁数据做说话人适配	GPT-SoVITS 等可做；训练成本和过拟合需测	留出文本与跨句式盲听
P2 定制微调	更长数据、角色一致性、长文本与批量生产	可做，但要独立数据工程与训练预算	长文稳定性、发音词典、连续性、成本

10.2 模型候选

候选	角色	优点	风险 / 需验证
Fun-CosyVoice 3.0	主路径	zero-shot、多语种/方言、指令式情感/语速/音量、流式	具体权重许可、显存与本地中文角色数据表现
GPT-SoVITS	few-shot 对照	社区成熟、短数据训练与中文工作流	版本碎片、权重/依赖来源、工程化接口与一致性
VITS	可控训练基线	结构清晰、适合展示从训练到推理	需要更多高质量数据，zero-shot 能力弱于新模型

10.3 合成管线



必须把语音克隆安全作为产品功能，而非文档脚注：保存同意凭证、限定用途和有效期、支持撤销、拒绝高风险冒用请求、对生成音频做可追踪标记，并保留每次参考音频与模型版本的审计记录。

11 项目 3：数据、情感控制与听感评测

单一 MOS 不能回答“像不像”“说对没有”“情绪对不对”；需要拆分评测。

11.1 数据规范

数据层	要求	拒收条件
参考音频	单说话人、少混响、无音乐、无 clipping、3-10 秒有效语音、文本可选	多人重叠、强噪、来源/同意不明
few-shot 适配	建议至少约 1 分钟以上有效语音，句子多样、转写准确	重复句、只有单一韵律、强后期处理
情感微调	每情感/强度均衡，标注者一致性，保留中性锚点	标签只靠文件名、类别高度不平衡
评测集	训练未见文本，含数字/专名/长句/问句/跨语种	与训练文本或参考音频重复

11.2 多维评测

问题	指标	设计
自然吗？	MOS / CMOS	随机双盲；真实录音作上界；至少报告均值与 95% CI
像本人吗？	Speaker similarity MOS + 说话人嵌入相似度	不同文本；防止只记住参考句
说对了吗？	ASR CER/WER + 人工错误分类	专名、数字、多音字、长句单独分桶
情绪对吗？	情感识别率、人工标签一致率、强度排序	中性/目标情绪 A-B；类别和强度分开
稳定吗？	失败率、重复/漏字、长文漂移、RTF、P95	短句、段落、章节三级压力测试
安全吗？	授权覆盖率、撤销 SLA、水印检出率、审计完整率	每个样本/请求都可追溯

11.3 盲听方案

- 样本：每系统 20-30 句，覆盖 5 类句式与目标情绪；对所有系统做响度匹配。
- 听众：先做 15-20 人内部筛选，再用 30+ 有效听众做阶段 Gate；剔除耳机/注意力检查失败者。
- 随机化：隐藏系统、随机顺序，同一听众避免连续听同一句的多个系统版本。
- 统计：MOS/相似度给 95% CI；成对比较报告效应量和多重比较校正；保存匿名原始评分。

停止条件：若情感增强导致 CER、相似度或自然度显著退化，不进入“情感更强”的下一阶段；优先修正文本前端、提示与参考音频，而非直接扩大微调。

12 项目 3：10 周 MVP 工作包

先证明 zero-shot 与安全闭环，再做情感和 few-shot；避免一上来训练大模型。

周	工作包	产物	Gate
W1	授权与数据协议	同意书字段、用途/到期/撤销、reference manifest	无授权样本无法进入系统
W2	参考音频 QC	SNR/混响/clipping/VAD/说话人一致性检查	低质样本给出可执行重录提示
W3-4	模型选型	CosyVoice 3 / GPT-SoVITS / VITS 小基准	质量、显存、RTF、许可表完整
W5	Zero-shot API	文本前端、克隆推理、缓存、失败码	3-10 秒代表集可稳定生成
W6	情感/韵律控制	情感、语速、音量、方言参数与限制	参数变化可感知且不显著伤害 CER
W7	few-shot 实验	约 1 分钟及更长数据的适配曲线	比 zero-shot 有稳定收益才保留
W8	评测平台	盲听任务、MOS/相似度/情感、统计脚本	可重复随机化与导出
W9	安全与审计	水印/标记、限额、撤销、审计、红队案例	高风险请求与无授权主体被拒
W10	长文与交付	分句拼接、角色一致性、Docker、演示与模型卡	P0/P1 Gate 通过，已知限制公开

建议 API

接口	说明	安全必填
POST /v1/voices	登记参考音频并质检	consent_id, subject_id, allowed_uses, expires_at
POST /v1/synthesis/jobs	创建合成作业	voice_id, text, emotion, purpose, watermark=true
DELETE /v1/voices/{id}	撤销后阻止新合成并清理派生缓存	actor, reason, audit_event
GET /v1/synthesis/jobs/{id}	结果、指标与审计摘要	model_revision, reference_hash, policy_decision

交付时不宣传“绝对不可识别水印”或“完全防滥用”。安全目标应表述为：提高可追溯性、降低未授权使用概率、缩短撤销响应，并明确剩余风险。

13 综合实施顺序与 18 周小团队路线

共享底座先行，项目 2 主线启动；项目 1 和 3 在依赖稳定后错峰并行。

工作流	W1	W2	W3	W4	W5	W6	W7	W8	W9	W10	W11	W12	W13	W14	W15	W16	W17	W18
共享底座	●	●																
2 修复质检 MVP		●	●	●	●	●	●											
1 ASR/分类评测					●	●	●	●	●									
1 Agent/RAG								●	●	●	●	●						
3 TTS 选型/克隆										●	●	●	●	●	●			
3 情感控制/听测														●	●	●	●	
三项目联调																	●	●

13.1 阶段 Gate

Gate	时间	必须满足	否则怎么做
G0 底座可用	W2	音频 manifest、对象存储、作业状态、版本与 CI	停止上层并行，先修复契约
G1 修复闭环	W7	原始/修复双轨、质量报告、ASR 与负向案例	降噪只保留为可选，不默认启用
G2 听析闭环	W12	工具 schema、Agent 有界循环、RAG 引用、人审	退回固定 workflow，Agent 只做解释
G3 声刻闭环	W17	授权、zero-shot、情感控制、盲听与审计	禁用公共克隆，仅内部受控演示
G4 联合验收	W18	端到端演示、容量、回归、运行手册、模型卡	逐项关闭 P0 缺陷后再发布

13.2 团队分工（3-4 人）

角色	主责	交叉责任
Audio/ML	DSP、增强、分类、TTS、数据与评测	模型卡、错误分析、GPU 性能
ML Platform/Backend	任务、存储、模型网关、API、MCP、LangGraph	可观测性、幂等、部署
Full-stack/Product	上传、报告、A-B 播放、盲听、人审与策略 UI	验收样例与用户研究
QA/Data（可兼职）	标注规范、Gold set、回归、听测、数据许可	红队、安全与发布签字

如果只有 1 人：不并行。先做 2 的 P0（8 周），再做 1 的 MVP（10 周），最后做 3 的 P0/P1（10 周），每阶段预留 15%-20% 缓冲；总体 26-34 周更现实。

14 环境、算力与成本控制

先测出“每分钟音频成本”，再决定模型大小和在线架构。

14.1 建议环境

用途	建议	说明
本地开发	16+ CPU 核、64GB RAM、1TB 可用 SSD	macOS/Windows 可写编排；音频工具需固定 FFmpeg 版本
GPU 基线	Linux + 单张 24GB NVIDIA GPU	足以做多数基线推理与小规模实验；具体显存以基准为准
并行/微调	48GB GPU 或 2×24GB，2-4TB NVMe	适合大模型、批量 ASR、TTS 适配和多实验
CPU worker	16-32 核、64GB RAM	解码、RNNoise、特征、报告、队列与数据搬运
存储	S3/MinIO + 生命周期策略	原始、派生、模型、评测集分桶；服务端加密

14.2 容量模型

每日 GPU 小时 ≈ 每日音频小时 × RTF ÷ 目标利用率。示例：若某链路综合 RTF=0.25、每天处理 400 小时音频、有效利用率 0.7，则约需 143 GPU 小时/日，即约 6 张持续工作的同等级 GPU。该数字仅示范计算方式，必须用目标硬件实测 RTF。

记录项	单位	作用
模型冷/热启动	秒	决定弹性扩缩与长驻策略
单文件 / 批量 RTF	处理秒 / 音频秒	容量规划与离线 SLA
P50/P95/P99	秒	用户体验与超时设置
显存峰值 / batch	GB / 条	选择模型、并发和 worker 数
存储放大率	派生字节 / 原始字节	生命周期与成本
每 1000 分钟成本	人民币或美元	模型路由和产品定价

14.3 版本锁定

- 容器锁定 CUDA、PyTorch、FFmpeg、模型包与系统依赖；权重单独记录 revision 与 SHA-256。
- 每份报告记录 processing_chain_id；任何模型或阈值变更都产生新版本。
- 生产环境禁止自动下载或自动执行未审核 remote code；模型通过离线供应链进入。
- 权重许可与代码许可分别审查。FunASR 官方文档明确提示：代码许可不等于每个模型权重许可。

15 工程化交付与 CI/CD

让实验结果能复现、服务能回滚、故障能定位。

15.1 Git 与发布

机制	最低要求
分支	main 受保护；短分支；PR 必须关联 issue/实验；禁止直接推生产
评审	代码、数据契约、模型卡/许可、性能变化四类 review checklist
CI	lint/type/unit → contract → 小型 Golden Audio → 容器扫描 → 构建镜像
夜间基准	完整音频回归、GPU 性能、质量指标、漂移报告；不阻塞日常 PR
发布	语义版本 + 镜像 digest + 模型 revision + 配置 bundle；蓝绿/金丝雀
回滚	代码、模型、阈值、知识库索引均可独立回滚

15.2 测试金字塔

层	频率	内容	耗时目标
Unit	每次提交	纯函数、DSP 参数、schema、策略、统计	< 5 分钟
Contract	每次 PR	模型适配器、MCP、API、对象存储、报告	< 10 分钟
Golden Audio	每次 PR	小集合质量/长度/时间码/字段	< 15 分钟
Full benchmark	夜间/候选发布	代表性数据、GPU 性能、置信区间	1-6 小时
Human eval	里程碑	MOS、A-B、内容审核、人审可用性	1-3 天

15.3 可观测性

- 统一 trace_id 跨上传、队列、模型、Agent 与报告；指标按 tenant、模型版本和场景分桶。
- 质量：无声、过短、ASR 空结果、unknown 分类、低相似度、降噪负增益、审核命中率。
- 系统：队列深度、GPU 利用率、OOM、重试、超时、缓存命中、对象存储错误。
- Agent：工具成功率、循环次数、证据覆盖率、人工接管率、拒答率与 token/调用成本。

> 发布门禁：任何质量改进都必须同时检查性能、成本、安全与长尾退化。模型平均分提升但 P95 延迟翻倍，或少数类召回下降，不视为无条件升级。

16 风险登记册与缓解

优先处理会让项目“看起来成功、实际不可用”的风险。

ID	风险	概率	影响	预防/缓解	触发信号
R1	数据泄漏导致分类指标虚高	高	高	group split；重复检测；跨域集	ID 98% 但 OOD 大幅下降
R2	降噪伤害语音/音乐细节	高	高	双轨评测；自动旁路；失败库	DNSMOS 升但 CER/听感变差
R3	Agent 幻觉或无限循环	中	高	有界图、schema、证据、预算、人审	循环/工具成本异常
R4	模型权重许可不清	中	高	逐权重审查；SBOM；替代模型	模型卡缺失或条款冲突
R5	语音克隆未授权/冒用	中	极高	同意、用途限制、撤销、水印、审计、拒绝策略	主体无法证明或用途高风险
R6	MOS 设计偏差	中	中	双盲、随机、响度匹配、CI、注意力检查	听众间方差极大
R7	GPU/OOM/吞吐不足	中	高	小模型路由、batch、量化、队列、容量压测	P95/队列持续增长
R8	真实域与公开集偏差	高	高	尽早采集真实小集；持续错误分析	公开集好、试点差
R9	敏感内容审核误判	高	高	分级策略、证据时间码、人审、申诉	高风险漏检或误报激增
R10	第三方依赖变更	中	中	版本 pin、镜像、权重缓存、契约测试	相同输入结果漂移

三条“停止线”

1）没有合法来源和可验证授权的说话人数据，不进行克隆或微调。
2）不能按源/说话人分组切分的数据，不对外宣称高准确率。
3）增强链在关键业务域导致 ASR、内容完整性或主观听感明显退化时，不默认启用，即使单项 DNSMOS 上升。

17 最终验收矩阵

具体阈值需在第一个代表性基准完成后冻结；这里给出验收结构与建议方向。

项目	验收面	最低交付	证据
共享	可复现	一条命令运行小型 benchmark；版本/参数/hash 完整	CI 记录、manifest、模型卡
共享	可靠性	幂等、重试、取消、超时、权限、审计；无静默失败	故障注入报告
2	修复	主场景平均改善且负向比例受控；ASR 非劣；响度合规	分场景表、A-B、CI、失败样本
2	质检	缺陷/内容命中有时间码和策略版本；人工可覆写	抽样复核、混淆矩阵
1	分类	ID + OOD + 开放集；Macro F1/混淆矩阵；无泄漏	数据卡、划分脚本、置信区间
1	ASR	代表域 CER/WER、时间戳、RTF、显存完成对比	可复现实验报告
1	Agent/RAG	任务完成、证据引用、越权隔离、有界循环、人审	场景测试与红队记录
3	克隆	授权可证；3-10 秒 zero-shot 稳定；相似度/自然度/正确度分开	盲听原始数据与统计
3	情感	目标情感可辨且强度可排序，不显著损害 CER/自然度	分类 + 人评 + A-B
3	安全	用途限制、撤销、水印/标记、审计、速率限制	策略测试与演练

演示验收脚本

演示	输入	现场可见结果
A 修复质检	3 段噪声/响度/敏感内容音频	A-B 播放、故障时间码、指标变化、报告
B 听析 Agent	一句话 + 10 段客服音频 + 私有政策	执行轨迹、转写、归因、引用、分类归档
C 声刻	已授权 3-10 秒参考 + 中性/高兴/严肃文本	音色对比、情绪切换、回译 CER、授权/水印记录
D 联动	低质参考音频或播客片段	失质检/修复，再理解或合成；完整 lineage

“演示成功”不等于“上线成功”。试点前还需：容量压测、数据保留政策、事故响应、模型许可确认、隐私影响评估、内容治理与用户申诉流程。

18 启动清单：前 10 个工作日

无需等待所有需求完美定义，先完成最小的事实收集与可重复基线。

日	行动	输出
D1	确认三项目的主业务场景、用户、离线/实时、中文/多语种、部署边界	一页 Scope + 非目标
D2	确认 GPU、存储、数据位置、隐私等级、外网与镜像策略	环境与权限清单
D3	建立 monorepo、pre-commit、pytest、CI、Docker 基础镜像	首个受保护 main
D4	定义 AudioAsset / Segment / ToolRun / Report schema	版本化 JSON Schema
D5	收集 30-50 段代表音频；建立合法来源与 hash 清单	最小真实域评测集
D6	实现探测、解码、重采样、VAD、LUFS、clipping	Audio Core v0
D7	接 DeepFilterNet3 与 RNNoise，产出 A-B	增强 baseline
D8	接 Whisper 与一个中文 ASR 候选，跑 CER/RTF/显存	ASR mini benchmark
D9	生成首份统一 JSON/PDF 质检报告	项目 2 最小闭环
D10	复盘错误、冻结 W3-W8 backlog 与首版门槛	可执行迭代计划

需要你提供的输入

优先级	输入	如果暂时没有
P0	目标机器/GPU、期望部署位置、可使用的模型许可证范围	以 Linux + 24GB GPU 开发基线估算
P0	每项目 20-50 个脱敏代表样本及合法使用证明	先用公开集，但不承诺业务指标
P0	分类标签、敏感内容策略、报告字段、情感标签	采用临时 schema，后续会产生返工
P1	延迟/吞吐/SLA、日处理量、保留期	只做离线 batch MVP
P1	对外展示还是内部作品集、是否商业化	按内部演示 + 可升级生产的设计

决策建议：立即启动项目 2 的前 10 日清单；第 5 日之前补齐最小真实域样本和授权。项目 1 的 ASR benchmark 可在 W2 后并行准备，但 Agent/RAG 等待共享契约稳定。项目 3 只先做许可审查与参考音频协议，不抢占早期 GPU 主线。

附录 A 参考资料与技术依据

仅列一手来源；访问时间 2026-09-20。具体模型与权重部署前应再次复核许可和版本。

编号	资料	URL
R1	OpenAI Whisper 官方仓库 - 代码与权重 MIT；含模型使用示例	https://github.com/openai/whisper
R2	FunASR 官方安装/安全与许可说明 - 软件许可不等于每个权重许可	https://github.com/modelscope/FunASR/blob/main/docs/installation/installation.md
R3	Qwen3-ASR 官方仓库 - 0.6B/1.7B、52 种语言/方言、流式/离线	https://github.com/QwenLM/Qwen3-ASR
R4	DeepFilterNet 官方仓库 - 48kHz 全频带增强、训练/推理与 MIT/Apache-2.0	https://github.com/Rikorose/DeepFilterNet
R5	RNNoise 官方仓库 - 低复杂度 RNN 噪声抑制	https://github.com/xiph/rnnoise
R6	Microsoft DNS Challenge 官方仓库 - 数据、基线与 DNSMOS 工具来源	https://github.com/microsoft/DNS-Challenge
R7	ITU-T P.862 页面 - PESQ 状态为 superseded，并指向 P.863	https://www.itu.int/ITU-T/recommendations/rec.aspx?rec=5374
R8	LangGraph 官方文档 - 长时有状态工作流、durable execution、人机协作	https://docs.langchain.com/oss/python/langgraph/overview
R9	Model Context Protocol 官方规范	https://modelcontextprotocol.io/specification/2025-06-18
R10	CosyVoice 官方仓库 - Fun-CosyVoice 3.0、zero-shot、多语种、指令控制与流式	https://github.com/FunAudioLLM/CosyVoice
R11	GPT-SoVITS 官方仓库 - few-shot voice cloning 工作流	https://github.com/RVC-Boss/GPT-SoVITS
R12	EBU R128 loudness recommendation	https://tech.ebu.ch/publications/r128

资料使用说明

本方案基于上述资料确认了候选模型的能力边界和许可注意点，但没有在当前空目录中实际下载权重、运行 benchmark 或验证目标硬件。因此所有性能、显存与质量结论都应以本项目的固定版本和代表性数据复测为准。

版本变更原则：候选模型如有新版本，只能通过相同评测集、相同硬件与相同报告模板比较后升级；禁止因 README 宣传指标直接替换生产模型。

附录 B 关键架构决策记录（ADR）

用于在项目启动时快速冻结边界，后续每次改变都留下理由和影响。

ADR	决定	理由	复核时点
ADR-001	采用共享 monorepo + 分产品 app	复用 Audio Core、模型适配器、评测与 CI；减少重复	团队超过 8 人或发布节奏冲突
ADR-002	先离线批处理，后流式	三项目首要价值在质量闭环；流式显著增加状态和资源复杂度	首个试点确认实时 SLA 后
ADR-003	项目 2 先于项目 1 和 3	先建立输入质量、ASR、评测与报告基础	G1 后
ADR-004	Agent 只编排有 schema 的工具	降低幻觉、越权和不可复现风险	工具数量或流程复杂度显著增加时
ADR-005	zero-shot 与微调分开命名	3-10 秒参考不等于训练；避免能力误述	完成 few-shot 数据曲线后
ADR-006	报告保留原始轨/修复轨双证据	防止单一质量分误导，支持申诉与复查	无
ADR-007	模型权重逐项许可审查	代码仓库许可不自动覆盖权重/数据	每次新增或升级模型
ADR-008	指标阈值在真实小集基线后冻结	当前没有数据，预设绝对阈值缺乏依据	D10 / 每次数据域重大变化

最终建议

这三个项目适合做成同一套“音频理解 - 修复质检 - 生成”的能力平台，而不是三个互不相干的 Demo。最稳妥的成功路径是：先用项目 2 建立可信输入与评测，再用项目 1 把能力变成可解释的业务流程，最后用项目 3 增加高价值生成能力并将授权与可追溯性做成产品的一部分。

文档结束